

Inteligência Artificial

Luís A. Alexandre

UBI

Ano lectivo 2019-20

Raciocínio Probabilístico

Ano lectivo 2019-20

1 / 31

Conteúdo

Raciocínio Probabilístico

Introdução

Redes Bayesianas

Inferência Aproximada

Amostragem por cadeias de Markov

Definições de Probabilidades

Leitura recomendada

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2019-20

2 / 31

Conteúdo

Raciocínio Probabilístico

Introdução

Redes Bayesianas

Inferência Aproximada

Amostragem por cadeias de Markov

Definições de Probabilidades

Leitura recomendada

Raciocínio Probabilístico

Ano lectivo 2019-20

3 / 31

Introdução

▶ Vamos ver como se consegue adquirir conhecimento incerto de forma eficiente.

▶ Depois veremos como fazer inferência probabilística de uma forma eficiente.

▶ Vamos falar de **redes Bayesianas**.

Raciocínio Probabilístico

Introdução

Ano lectivo 2019-20

4 / 31

Introdução

▶ Vimos na aula anterior que com a distribuição conjunta de probabilidade podemos responder a qualquer questão sobre o domínio.

▶ O problema é que essa distribuição fica muito difícil de obter com o aumento do número de variáveis.

▶ Hoje vamos aprender uma nova estrutura de dados: a **rede Bayesiana** (RB), que permite representar a dependência entre variáveis.

▶ As RBs permitem representar qualquer distribuição conjunta de probabilidade.

Raciocínio Probabilístico

Introdução

Ano lectivo 2019-20

5 / 31

Conteúdo

Raciocínio Probabilístico

Introdução

Redes Bayesianas

Inferência Aproximada

Amostragem por cadeias de Markov

Definições de Probabilidades

Leitura recomendada

Raciocínio Probabilístico

Redes Bayesianas

Ano lectivo 2019-20

6 / 31

## Redes Bayesianas

- ▶ Uma RB é um **grafo dirigido** que contém informação probabilística em cada nodo:
  - ▶ Cada nodo corresponde a uma variável aleatória (discreta ou contínua).
  - ▶ Uma aresta do nodo  $X$  para o  $Y$  significa que  $X$  é o pai de  $Y$ .
  - ▶ O grafo não contém ciclos.
  - ▶ Cada nodo  $X_i$  guarda a distribuição probabilística condicional  $P(X_i | Pais(X_i))$  que quantifica os efeitos dos pais no nodo em causa.
- ▶ Quando temos uma aresta a partir de  $X$  e a chegar a  $Y$  sabemos que  $X$  influencia  $Y$ .
- ▶ Como as causas estão por detrás dos efeitos, nas RBs, **os nodos causa devem ser pais** dos nodos efeito.

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2019-20

7 / 31

## Redes Bayesianas: exemplo

- ▶ Vejamos um exemplo: um alarme instalado em casa.
- ▶ Deteta bem assaltantes mas por vezes dispara com tremores de terra.
- ▶ Existem 2 vizinhos, João e a Maria, que prometeram que nos ligavam se o alarme disparasse.
- ▶ O João liga quase sempre quando ouve o alarme mas por vezes confunde o som do telefone a tocar com o do alarme e liga também nesse caso.
- ▶ A Maria ouve música alto e, muitas das vezes, acaba por não ouvir o alarme a tocar.
- ▶ Dada a informação sobre as chamadas recebidas (ou não) dos dois vizinhos, queremos saber qual a probabilidade de existir um assalto.

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2019-20

9 / 31

## Redes Bayesianas: exemplo

- ▶ Os nodos *Assalto* e *TremorTerra* só têm associados a probabilidade à priori de ocorrerem visto não dependerem de mais nenhum nodo no nosso problema.
- ▶ Os restantes têm a probabilidade de o respetivo acontecimento ter lugar, face aos acontecimentos de que eles dependem.
- ▶ Exemplo: a probabilidade do alarme tocar dado que não houve assalto e houve um tremor de terra é de 0.29.
- ▶ Os problemas que referimos com o João a confundir o toque do telefone com o toque do alarme e da Maria não ouvir o alarme por causa da música, aparecem condensados nas probabilidades de eles telefonarem dado que o alarme tocou.

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2019-20

11 / 31

## Redes Bayesianas

- ▶ Um perito pode facilmente indicar quais são as causas e os respetivos efeitos: permite construir a topologia da RB.
- ▶ Depois resta determinar as probabilidades condicionais a colocar em cada nodo.
- ▶ Com estes dois elementos, conseguimos achar a distribuição conjunta para todas as variáveis.
- ▶ Se um nodo tem  $m$  nodos pai que são variáveis booleanas, então a sua probabilidade condicional pode ser representada numa tabela com  $2^m$  entradas.
- ▶ Nodos que não estão ligados na RB são nodos **condicionalmente independentes**.

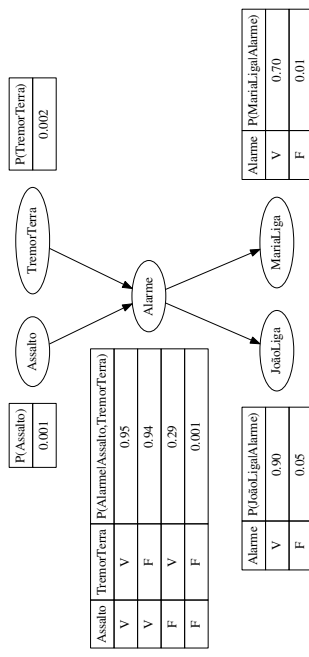
Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2019-20

8 / 31

## Redes Bayesianas: exemplo



Adaptada de Russel &amp; Norvig, p.512

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2019-20

10 / 31

## Redes Bayesianas: exemplo

- ▶ A probabilidade conjunta será obtida com

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | Pais(x_i)) \quad (1)$$

onde os  $x_i$  representam  $X_i = x_i$ .

- ▶ Exemplo: achar a probabilidade de o alarme tocar sem ter havido assalto nem tremor de terra e o João e a Maria ligarem a avisar que o alarme tocou:

$$P(\text{JoãoLiga}, \text{MariaLiga}, \text{Alarme}, \neg \text{TremorTerra}) = \\ P(\text{JoãoLiga} | \text{Alarme}) P(\text{MariaLiga} | \text{Alarme}) P(\text{Alarme} | \neg \text{Assalto}, \neg \text{TremorTerra}) P(\neg \text{Assalto}) P(\neg \text{TremorTerra}) = \\ 0.9 \times 0.7 \times 0.001 \times 0.999 \times 0.998 = 0.000638$$

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2019-20

12 / 31

## Construir Redes Bayesianas

- ▶ Vejamos como construir uma RB.
- ▶ **Nodos:** determinar o conjunto de variáveis necessárias para modelar o domínio,  $\{X_1, \dots, X_n\}$ . Ordenar de modo a que as causas apareçam antes dos efeitos.
- ▶ **Arestas:** Para cada  $i$  de 1 a  $n$ , fazer:

- ▶ Escolher em  $\{X_1, \dots, X_{i-1}\}$  os pais que tornem a seguinte equação válida:

$$P(X_i|X_1, \dots, X_{i-1}) = P(X_i|\text{Pais}(X_i))$$

sendo que  $\text{Pais}(X_i) \subset \{X_1, \dots, X_{i-1}\}$ .

- ▶ Criar uma aresta entre cada pai e  $X_i$ .
- ▶ Escrever a  $P(X_i|\text{Pais}(X_i))$ .

## Construir Redes Bayesianas


- ▶ Exemplo: imaginemos que faltava colocar o nodo *MariaLiga* na figura acima.
- ▶ Sabemos que este nodo é influenciado por *Assalto* e *TremorTerra*, mas não diretamente, através apenas de *Alarme*.
- ▶ Também sabemos que o *JoãoLiga* não tem influência em *MariaLiga*.
- ▶ Isto traduz-se em

$$P(\text{MariaLiga}|\text{JoãoLiga}, \text{Alarme}, \text{TremorTerra}, \text{Assalto}) = P(\text{MariaLiga}|\text{Alarme})$$

- ▶ Isto implica que *Alarme* é o nodo pai de *MariaLiga*.
- ▶ Uma propriedade importante das RB é que **não têm valores redundantes**, logo não há inconsistências numa RB: nunca são violados os axiomas das probabilidades.

## Redes Bayesianas: exercício

- ▶ Dada a seguinte RB, calcule a probabilidade de estar a chover ( $C$ ) dado que a relva está molhada ( $R$ ).



Chuva	P(Aspersor Chuva)
V	0.01
F	0.40

Aspersor	Chuva	P(RelvaMolhada Aspersor, Chuva)
V	V	0.99
V	F	0.90
F	V	0.80
F	F	0.00

Adeptado de [en.wikipedia.org/wiki/File:SimpleBayesian.svg](https://en.wikipedia.org/wiki/File:SimpleBayesian.svg)

## Redes Bayesianas: exercício

- ▶ Queremos saber  $P(C|R)$ .

- ▶ Sabemos que

$$P(C|R) = \frac{P(C, R)}{P(R)}$$

- ▶ Precisamos então de obter  $P(C, R)$  e  $P(R)$ .

- ▶ Da equação (1) sabemos que

$$P(C, A, R) = P(C)P(A|C)P(R|A, C)$$

- ▶  $P(C, R) = \sum_{A \in \{V, F\}} P(C, A, R) = P(C, A, R) + P(C, \neg A, R) = 0.2 \times 0.01 \times 0.99 + 0.2 \times 0.99 \times 0.8 = 0.1604$

## Redes Bayesianas: exercício

- ▶ Também sabemos que

$$P(R) = \sum_{A, C \in \{V, F\}} P(R, A, C) =$$

$$P(R, A, C) + P(R, \neg A, C) + P(R, A, \neg C) + P(R, \neg A, \neg C)$$

- ▶  $P(R, A, C) = P(R|A, C)P(A|C)P(C) = 0.99 \times 0.01 \times 0.2 = 0.00198$
- ▶  $P(R, \neg A, C) = P(R|\neg A, C)P(\neg A|C)P(C) = 0.8 \times 0.99 \times 0.2 = 0.1584$
- ▶  $P(R, A, \neg C) = P(R|A, \neg C)P(A|\neg C)P(\neg C) = 0.9 \times 0.4 \times 0.8 = 0.288$
- ▶  $P(R, \neg A, \neg C) = P(R|\neg A, \neg C)P(\neg A|\neg C)P(\neg C) = 0$
- ▶ Temos então  $P(R) = 0.44838$ .
- ▶ Finalmente,  $P(C|R) = 0.1604 / 0.44838 = 0.3577$ .

## Conteúdo

Raciocínio Probabilístico

Introdução

Redes Bayesianas

**Inferência Aproximada**

Amostragem por cadeias de Markov

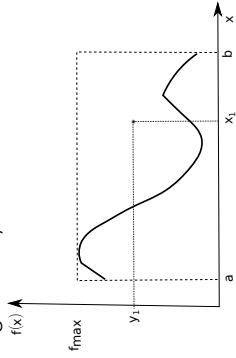
Definições de Probabilidades

Leitura recomendada

## Inferência Aproximada

- ▶ Dado que para casos reais o cálculo da **inferência exata** não é possível devido ao custo computacional, usa-se em geral **inferência aproximada**.
- ▶ Chamam-se **algoritmos de Monte Carlo** a métodos de amostragem aleatória, que fornecem aproximações baseadas na geração de muitas amostras aleatórias.
- ▶ Estamos interessados em algoritmos que permitam estimar probabilidades à posteriori.
- ▶ Vamos ver primeiro um exemplo simples de uso do método de Monte Carlo e depois a inferência baseada em cadeias de Markov.

## Método de Monte Carlo

- ▶ Vejamos como usar o método de MC para determinar uma quantidade determinística, o valor de um integral.
  - ▶ Consideremos a seguinte função
- 
- ▶ Queremos achar o valor de  $I = \int_a^b f(x) dx$ .
  - ▶ A área do retângulo tracejado é  $A = (b - a) \times f_{max}$ .
  - ▶ A probabilidade escolher um ponto ao acaso dentro do retângulo e ele pertencer a zona por baixo da função  $f(x)$  é  $P = I/A$ .

## Método de Monte Carlo


- ▶ Podemos determinar  $P$  experimentalmente, gerando muitos pontos aleatórios e verificando se estão ou não na área de baixo da curva:
  1. Criar um contador,  $c = 0$ .
  2. Repetir  $n$  vezes os passos 3 a 5:
  3. Escolher 2 valores aleatórios de uma distribuição uniforme entre  $[0, 1]$ ,  $v_1$  e  $v_2$ .
  4. Criar um ponto no retângulo com as coordenadas  $x_1 = a + v_1 \times (b - a)$  e  $y_1 = v_2 \times f_{max}$ .
  5. Se  $y_1 \leq f(x_1)$  incrementar o contador  $c$ .
  6. A estimativa fica  $P = c/n$ .
- ▶ Quando tivermos achado  $P$ , torna-se imediato achar o valor do integral:  $I = P \times A$ .

## Amostragem por cadeias de Markov

- ▶ Vejamos então como usar as cadeias de Markov para estimar probabilidades à posteriori, no âmbito das redes Bayesianas.
- ▶ A família de algoritmos de amostragem por cadeias de Markov, normalmente chamados métodos MCMC (Markov Chain Monte Carlo) geram cada nova amostra fazendo uma alteração aleatória na amostra anterior.
- ▶ Há vários algoritmos dentro dos MCMC, mas vamos ver apenas um: a Amostragem de Gibbs.

## Amostragem de Gibbs

- ▶ Começemos por definir o **lencol de Markov (LM)** de uma variável aleatória: os seus pais, filhos e os outros pais dos seus filhos.



Russel & Norvig, p.518

- ▶ A distribuição de probabilidade de um nodo só depende da distribuição conjunta das variáveis no seu LM.

## Amostragem de Gibbs

- ▶ Para obtermos uma amostra para  $X_i$  vamos levar em conta apenas os valores das variáveis que pertencem ao seu LM.
- ▶ O que a AG faz é:
  - ▶ partir de um estado em que as variáveis observadas têm os seus valores fixos.
  - ▶ gerar um novo estado mudando de forma aleatória o valor das restantes variáveis.
  - ▶ Em cada iteração:
    - ▶ Escolher uma variável  $X$
    - ▶ Calcular  $P(X=\text{verdade} \mid \text{as restantes variáveis})$
    - ▶ Atribuir a  $X$  ser verdade a probabilidade calculada
  - ▶ Repetir o processo muitas vezes.
  - ▶ A frequência com que uma variável é verdade é a sua probabilidade à posteriori.
- ▶ Este algoritmo converge para as verdadeiras probabilidades quando esses valores deixam de variar significativamente.

## Amostragem de Gibbs

- ▶ Como achar  $P(X=\text{verdade} \mid \text{as restantes variáveis})$ ?
- ▶ Usamos o LM: sabemos que cada variável só depende dos pais, filhos e outros pais dos seus filhos.
- ▶ Então o problema passa a ser achar  $P(X=\text{verdade} \mid LM(X))$ .

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2019-20

25 / 31

## Amostragem de Gibbs: exemplo

- ▶ Queremos achar  $P(\text{Chuva} \mid \text{Aspersor}, \text{RelvaMolhada})$ .
- ▶ Qual é o LM de Chuva?
- ▶ As variáveis *Aspersor* e *RelvaMolhada* ficam fixas com os valores que foram observados, ou seja, as variáveis  $[\text{Nublado}, \text{Aspersor}, \text{Chuva}, \text{RelvaMolhada}]$  ficam inicialmente com os valores  $[?, V, ?, V]$ .
- ▶ Depois inicializamos aleatoriamente as restantes variáveis do LM, logo poderíamos obter o estado inicial  $[V, V, F, V]$ .
- ▶ Agora a AG o que faz é amostrar as variáveis não observadas (*Nublado* e *Chuva*), repetidamente.

Luís A. Alexandre (UBI)

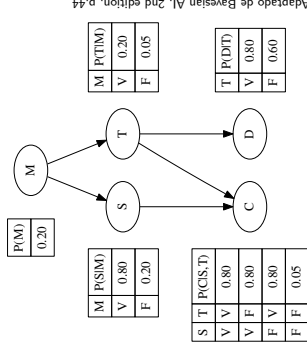
Inteligência Artificial

Ano lectivo 2019-20

27 / 31

## RB: exercício

- ▶ O cancro metastático (M) é uma possível causa de tumores no cérebro (T) e também aumenta o cálcio serum (S). Tanto um tumor cerebral como o aumento do cálcio serum podem explicar um coma (C). Sabemos também que os tumores cerebrais podem causar dores de cabeça fortes (D).
- ▶ Represente esta informação numa RB (sem atribuição de probabilidades).
- ▶ Dada a seguinte RB para o problema descrito, ache o valor da probabilidade de um doente ter um tumor cerebral sabendo que tem fortes dores de cabeça.



Luís A. Alexandre (UBI)

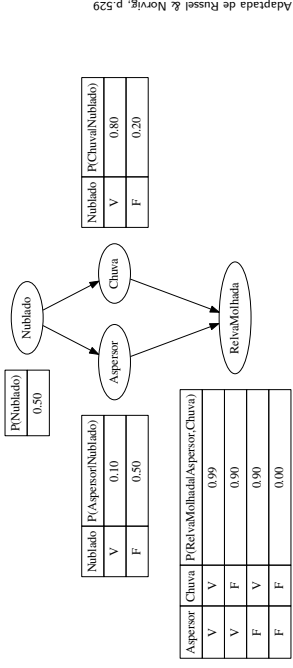
Inteligência Artificial

Ano lectivo 2019-20

29 / 31

## Amostragem de Gibbs: exemplo

- ▶ Imaginemos que estamos a estimar probabilidades no seguinte problema, e que a ordem topológica das variáveis é definida como  $[\text{Nublado}, \text{Aspersor}, \text{Chuva}, \text{RelvaMolhada}]$ .



Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2019-20

26 / 31

## Amostragem de Gibbs: exemplo

- ▶ Exemplo:

- ▶ *Nublado* é amostrado, dados os valores do seu LM, ou seja,  $P(\text{Nublado} \mid \text{Aspersor}, \neg \text{Chuva})$ . Se *Nublado* = F então o novo estado é  $[F, V, F, V]$ .
- ▶ *Chuva* é amostrado, dados os valores do seu LM, ou seja,  $P(\text{Chuva} \mid \neg \text{Nublado}, \text{Aspersor}, \text{RelvaMolhada})$ . Se *Chuva* = V então o novo estado é  $[F, V, V, V]$ .
- ▶ Cada estado visitado durante este processo é uma amostra que permite estimar a questão original sobre a variável *Chuva*.
- ▶ Se este processo resultar em 20 estados com *Chuva* = V e 60 com *Chuva* = F então a resposta será que a  $P(\text{Chuva} \mid \text{Aspersor}, \text{RelvaMolhada}) = 0.25$ .

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2019-20

28 / 31

- ▶ A **probabilidade conjunta** de  $n$  eventos:
 
$$P(A_1, A_2, \dots, A_n) = \prod_{i=1}^n P(A_i \mid A_1, \dots, A_{i-1}) \quad (2)$$
- ▶ A **probabilidade conjunta** de  $n$  eventos **independentes** é o produto das suas probabilidades:
 
$$P(A_1, A_2, \dots, A_n) = \prod_{i=1}^n P(A_i) \quad (3)$$
- ▶ **Probabilidade condicional** relativa a duas variáveis A e B:
 
$$P(A|B) = \frac{P(A, B)}{P(B)} \quad (4)$$
- ▶ Se Z representa o conjunto de todos os valores das variáveis envolvidas no problema, então podemos obter  $P(A)$  **marginalizando**:
 
$$P(A) = \sum_{B \in Z} P(A, B) \quad (5)$$
- ▶ Se as probabilidades são condicionais em vez de conjuntas (aplicar a equação (4) à anterior):
 
$$P(A) = \sum_{B \in Z} P(A|B)P(B) \quad (6)$$
- ▶ **Regra de Bayes**

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} \quad (7)$$
- ▶ Se duas variáveis A e B são **independentes** então
 
$$P(A|B) = P(A) \text{ e } P(B|A) = P(B) \text{ e } P(A, B) = P(A)P(B) \quad (8)$$
- ▶ Se duas variáveis A e B são **independentes condicionalmente**, dada a variável C então
 
$$P(A, B|C) = P(A|C)P(B|C) \quad (9)$$
- ▶ Cada nodo numa RB guarda a seguinte probabilidade condicional:
 
$$P(A_i | \text{Pa}(A_i)) \quad (10)$$
- ▶ Numa RB, a **probabilidade conjunta** obtém-se através do produto das distribuições de todos os nodos.

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2019-20

30 / 31

## Leitura recomendada

- ▶ Russell e Norvig, cap. 14.