

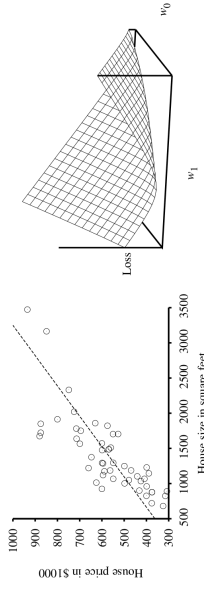
<p>Inteligência Artificial</p> <p>Luís A. Alexandre</p> <p>UBI</p> <p>Ano lectivo 2019-20</p>		<p>Inteligência Artificial</p> <p>1 / 30</p>
<p>Luís A. Alexandre (UBI)</p>	<p>Aprendizagem a partir de observações</p> <p>Introdução</p>	<p>Ano lectivo 2019-20</p> <p>1 / 30</p>

<p>Luís A. Alexandre (UBI)</p>	<p>Inteligência Artificial</p> <p>4 / 30</p>	<p>Ano lectivo 2019-20</p> <p>2 / 30</p>
<p>Conteúdo</p>	<p>Aprendizagem a partir de observações</p> <p>Introdução</p> <p>Regressão Linear</p>	<p>Regressão Logística</p> <p>Redes Neuronais</p> <p>Máquinas de Vetores de Suporte</p> <p>Leitura recomendada</p>

<p>Introdução</p> <p>▶ Vamos estudar um conjunto de técnicas que nos permitem aprender de forma supervisionada a partir de um conjunto de dados.</p> <p>▶ Estas abordagens são complementares à árvores de decisão que estudámos na aula anterior.</p> <p>▶ Veremos tanto abordagens para classificação como para regressão.</p>		<p>Inteligência Artificial</p> <p>3 / 30</p>
<p>Luís A. Alexandre (UBI)</p>	<p>Aprendizagem a partir de observações</p> <p>Introdução</p>	<p>Ano lectivo 2019-20</p> <p>3 / 30</p>

<p>Luís A. Alexandre (UBI)</p>	<p>Inteligência Artificial</p> <p>4 / 30</p>	<p>Ano lectivo 2019-20</p> <p>4 / 30</p>
<p>Conteúdo</p>	<p>Aprendizagem a partir de observações</p> <p>Regressão Linear</p>	<p>Regressão Logística</p> <p>Redes Neuronais</p> <p>Máquinas de Vetores de Suporte</p> <p>Leitura recomendada</p>

<p>Regressão Linear</p> <p>▶ Vamos ver como fazer regressão linear: ajustar uma reta aos dados.</p> <p>▶ Podemos escrever a equação de uma reta como</p> $y = w_1x + w_0 \quad (1)$ <p>onde os parâmetros podem ser colocados num vetor de pesos $\mathbf{w} = [w_0; w_1]$.</p> <p>▶ Podemos então reescrever a equação da reta como</p> $h_{\mathbf{w}}(x) = w_1x + w_0 \quad (2)$		<p>Inteligência Artificial</p> <p>5 / 30</p>
<p>Luís A. Alexandre (UBI)</p>	<p>Aprendizagem a partir de observações</p> <p>Regressão Linear</p>	<p>Ano lectivo 2019-20</p> <p>5 / 30</p>

<p>Luís A. Alexandre (UBI)</p>	<p>Inteligência Artificial</p> <p>6 / 30</p>	<p>Ano lectivo 2019-20</p> <p>6 / 30</p>
<p>Regressão Linear</p>	<p>Aprendizagem a partir de observações</p> <p>Regressão Linear</p>	<p>Figura de Russell & Norvig</p> 

Regressão Linear

- ▶ Para fazermos o ajuste da reta temos que determinar os pesos. Isso faz-se minimizando o **erro empírico** (por vezes chamado loss em inglês):

$$EE(h_{\mathbf{w}}) = \sum_{i=1}^N (y_i - h_{\mathbf{w}}(x_i))^2 \quad (3)$$

onde N é o número de pontos do conjunto de dados.

- ▶ Escolhemos então os pesos que minimizam este erro:

$$\mathbf{w}^* = \arg \min_{\mathbf{w}} EE(h_{\mathbf{w}})$$

- ▶ Temos que achar as derivadas parciais em ordem às variáveis que estamos a procurar, w_0 e w_1 , e igualar a zero:

$$\frac{\partial EE(h_{\mathbf{w}})}{\partial w_0} = 0 \quad \frac{\partial EE(h_{\mathbf{w}})}{\partial w_1} = 0 \quad (4)$$

Regressão Linear

- ▶ A solução é

$$w_1 = \frac{N \sum (x_i y_i) - (\sum x_i)(\sum y_i)}{N(\sum x_i^2) - (\sum x_i)^2} \quad (5)$$
$$w_0 = \frac{1}{N} \left(\sum y_i - w_1 \sum x_i \right)$$

- ▶ O que estamos a fazer ao determinar estes pesos é a escolher o mínimo da função mostrada na figura anterior (lado direito): é convexa, logo não tem mínimos locais.
- ▶ O exemplo e as equações apresentadas são para o caso unidimensional (regressão univariada), mas podemos trabalhar com dados vetoriais e aí temos a regressão multivariada.

Conteúdo

Aprendizagem a partir de observações

Introdução

Regressão Linear

Regressão Logística

Redes Neuronais

Máquinas de Vetores de Suporte

Leitura recomendada

Regressão Logística

- ▶ As funções lineares podem ser usadas não só para regressão mas também para classificação.
- ▶ Neste caso vamos criar um **classificador** linear baseado na seguinte função, chamada de logística:

$$\text{logistica}(x) = \frac{1}{1 + e^{-x}} \quad (6)$$

- ▶ A nossa hipótese será

$$h_{\mathbf{w}}(\mathbf{x}) = \text{logistica}(\mathbf{w} \cdot \mathbf{x}) = \frac{1}{1 + e^{-\mathbf{w} \cdot \mathbf{x}}} \quad (7)$$

- ▶ Consideramos as entradas como sendo um vetor e não um escalar como no exemplo anterior: agora temos \mathbf{x} e não x .

Descida do gradiente

- ▶ Podemos achar os pesos com um processo iterativo: a **descida do gradiente**.
- ▶ Na realidade este processo é muito usado também em outros classificadores, quando não é possível obter a solução exata para os valores dos pesos que minimizam o erro empírico.


- ▶ Algoritmo:

$\mathbf{w} \leftarrow$ valor aleatório no espaço dos pesos
enquanto não exista convergência fazer:
para cada w_i em \mathbf{w} fazer:

$$w_i \leftarrow w_i - \alpha \frac{\partial}{\partial w_i} EE(\mathbf{w}) \quad (8)$$

- ▶ Chamamos ao α a **taxa de aprendizagem**.

Descida do gradiente




Regressão Logística

- ▶ Para aplicarmos a descida do gradiente no caso da RL para obtermos os pesos necessários, devemos achar o valor do gradiente na expressão (8).
- ▶ A expressão da atualização dos pesos fica então a seguinte:

$$w_i \leftarrow w_i + \alpha(y - h_w(\mathbf{x}))h_w(\mathbf{x})(1 - h_w(\mathbf{x}))x_i \quad (9)$$



Regressão Logística

- ▶ Exemplo: a linha ajustada aos dados do valor dum casa pode ser agora a fronteira de decisão entre duas classes: as casas baratas e as caras.



Redes Neuronais

- ▶ Alguns investigadores, inspirados pela única coisa inteligente que conhecemos, o cérebro humano, decidiram criar modelos inspirados no nosso cérebro.
- ▶ O primeiro modelo de um neurónio artificial foi proposto em 1943.
- ▶ O seu funcionamento é simples: quando os valores das suas entradas excedem um limiar, o neurónio “dispara”.



Regressão Logística

- ▶ Como se pode usar a linha que obtemos na RL para classificar?
- ▶ Podemos usar essa linha para separar os dados pertencentes a duas classes: a linha passa a chamar-se **fronteira de decisão**.
- ▶ Essa linha separa os pontos de duas classes: os que ficam de um lado e do outro da linha.

Conteúdo

Aprendizagem a partir de observações
Introdução
Regressão Linear

Regressão Logística
Redes Neuronais
Máquinas de Vetores de Suporte
Leitura recomendada

Redes Neuronais

- ▶ Do ponto de vista formal, os valores das **entradas**, x_i , num neurónio são multiplicadas por um **peso**, w_i , e somadas para produzirem uma média pesada:
$$s = \sum_{i=0}^n x_i w_i \quad (10)$$
- ▶ Esta soma é depois passada por uma função não linear, $f(s)$, chamada a **função de ativação**.
- ▶ A saída ou **ativação** do neurónio obtém-se com $y = f(s)$.
- ▶ Existem muitas propostas para $f(s)$, mas uma muito usada é a logística que vimos atrás (também chamada de **sigmóide**). Neste caso a saída do neurónio obtém-se com


$$y = \text{logística}(s) = \frac{1}{1 + e^{-\sum_{i=0}^n x_i w_i}} \quad (11)$$

Redes neurais

- ▶ Exemplo: vamos usar um neurônio para implementar a função AND (E lógico) entre duas entradas. A função de ativação que vamos usar é dada por


$$f(x) = \begin{cases} 0, & x \leq 0 \\ 1, & x > 0 \end{cases}$$

- ▶ Podemos representar estes dados num plano, que neste caso representa o espaço de entrada do problema:



Perceptrão

- ▶ Os neurónios estão normalmente organizados em camadas.
- ▶ Uma rede neuronal com apenas uma camada de neurónios chama-se um **perceptrão**:



- ▶ Neste exemplo temos uma camada com apenas 2 neurónios.
- ▶ Para usamos uma rede para classificar dados podemos usar tantos neurónios quantas as classes que queremos processar.

Conteúdo

Aprendizagem a partir de observações

Introdução

Regressão Linear

Regressão Logística


Redes Neurais

Máquinas de Vetores de Suporte

Leitura recomendada

Redes neurais

- ▶ Como fazer para classificarmos os dados de entrada usando um neurónio?
- ▶ Testar os seguintes pesos: $w_0 = -1.5$, $w_1 = 1$, $w_2 = 1$.
- ▶ Exercício: OR e XOR.



- ▶ Como obter os pesos em geral: usamos a descida do gradiente e a expressão que usamos é a já vista no caso da regressão logística (equação (9)) quando a função de ativação é a sigmóide.

Redes neurais

- ▶ As RNs são muito versáteis e podem ser usadas para todos os tipos de aprendizagem que referimos na aula anterior: não supervisionada, supervisionada (tanto para classificação como para regressão), semi-supervisionada e para aprendizagem por reforço.
- ▶ Aqui estudámos apenas a RN mais simples: o perceptrão.
- ▶ Vimos que implementa um hiperplano no espaço de entrada (dos dados) podendo apenas resolver problemas que sejam linearmente separáveis.
- ▶ Existem muitas mais RNs, todas elas mais potentes que um simples perceptrão, e que hoje em dia são as responsáveis pelos enormes avanços da IA. Para as estudar existem outras UCs em mestrado e doutoramento que focam os detalhes.

Máquinas de Vetores de Suporte

- ▶ As **Máquinas de Vetores de Suporte** (em inglês SVMs) têm algumas propriedades interessantes:
 - ▶ constroem uma fronteira de decisão que tem a **margem máxima** em relação aos pontos do conjunto de treino
 - ▶ embora implementem um separador linear, conseguem obter fronteiras de decisão complexas construindo esse separador linear num **espaço de maior dimensionalidade que o de entrada**
 - ▶ são resistentes ao sobre-ajuste
- ▶ Vimos antes que um método como a regressão logística acha uma fronteira de decisão entre 2 classes usando para isso todos os pontos do conjunto de treino. Numa MVS alguns pontos são mais importantes que outros.

Máquinas de Vetores de Suporte

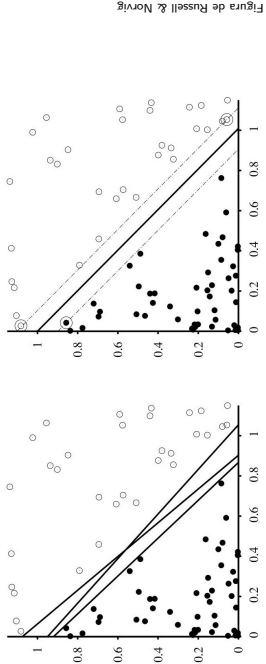


Figura de Russell & Norvig

Máquinas de Vetores de Suporte

- ▶ A solução para achar os pesos que permitem construir o plano separador pode ser obtida resolvendo:

$$\arg \max_{\alpha} \sum_j \alpha_j - 0.5 \sum_{j,k} \alpha_j \alpha_k y_j y_k (\mathbf{x}_j \cdot \mathbf{x}_k) \quad (12)$$

onde $\alpha_j \geq 0$ e $\sum_j \alpha_j y_j = 0$.

- ▶ Este é um problema de **otimização quadrática** que pode ser resolvido com software específico: obtemos o vetor α .
- ▶ Podemos depois obter os pesos com $\mathbf{w} = \sum_i \alpha_i \mathbf{x}_i$
- ▶ Há 3 características importantes na equação (12):
 - ▶ é uma expressão **convexa**: tem apenas um máximo global que pode ser encontrado de forma eficiente;
 - ▶ os dados só aparecem em produtos de pares de pontos;
 - ▶ os pesos α_j associados aos pontos são zero menos nos **vetores de suporte**: os pontos mais perto do separador.

Máquinas de Vetores de Suporte





Figura de Russell & Norvig

Máquinas de Vetores de Suporte

- ▶ Em vez de minimizarem o erro empírico no conjunto de treino, as MVS tentam minimizar o erro de generalização.
- ▶ Como, se não sabemos que pontos serão usados para teste?
- ▶ Para o conseguir as MVS escolhem o plano separador que esteja mais afastado dos pontos vistos até ao momento: é o **separador de margem máxima**.
- ▶ A **margem** é o dobro da distância entre o separador e o ponto mais próximo (aparece como a largura da zona tracejada na figura anterior).

Máquinas de Vetores de Suporte

- ▶ Como se consegue usar uma MVS quando os exemplos não são linearmente separáveis?
- ▶ Se mapearmos os dados para um espaço de dimensão suficientemente elevada conseguimos separá-los com um hiperplano.
- ▶ Em geral, para um problema com N pontos, é sempre possível encontrar uma forma de os separar linearmente num espaço de dimensão $N - 1$ ou superior.

Leitura recomendada

- ▶ Russell e Norvig, sec. 18.6, 18.7, 18.8.